

Documentación del Proyecto: Sistema de Recomendación de Series de Televisión

Índice

1. Introducción
2. Objetivos
3. Arquitectura del Sistema
4. Descripción del Dataset
5. Procesamiento de Datos
6. Generación de Embeddings
7. Sistema de Recomendación
8. Base de Datos (Cassandra)
9. Captura de Actividad de Usuarios (Apache Kafka)
10. Interfaz Web
11. Futuras Mejoras
12. Requisitos Técnicos

Introducción

Este proyecto consiste en el desarrollo de un sistema de recomendación de series de televisión basado en el contenido textual de los resúmenes de cada serie. A partir de un dataset, se realiza limpieza, transformación, y generación de embeddings para obtener recomendaciones personalizadas usando distancia coseno.


El sistema se complementa con una interfaz web que permite a los usuarios interactuar con el motor de recomendaciones. Las interacciones (clics) se registran y procesan en tiempo real mediante Apache Kafka. Los datos persistentes se almacenan en una base de datos distribuida Apache Cassandra.

Url del proyecto: <https://github.com/ManuelRodrSha/proyecto4>

Objetivos

- Preprocesar y limpiar un dataset de series de televisión.
- Generar representaciones vectoriales (embeddings) de los resúmenes.
- Utilizar distancia coseno para calcular similitudes y generar recomendaciones.
- Almacenar los datos en una base de datos NoSQL escalable (Cassandra).
- Capturar el comportamiento del usuario mediante Kafka para análisis futuro.
- Proveer una interfaz web intuitiva para los usuarios finales.

Arquitectura del Sistema



Descripción del Dataset

El dataset contiene información sobre series de televisión, entre los campos más relevantes se encuentran:

- **show_id**: Identificador de la serie.
- **name**: Título de la serie.
- **genre_name**: Lista de géneros asociados.
- **overview**: Resumen descriptivo del argumento de la serie.
- **embeddings**: Embeddings del overview.
- **embeddings_con_genero**: Embeddings del overview junto al genre_name.
- **vote_count**: Número total de votaciones.
- **vote_average**: Valoración promedio.

Procesamiento de Datos

El proceso de limpieza incluye:

1. **Eliminación de duplicados.**
2. **Tratamiento de valores nulos**, especialmente en los campos **overview** y **name**.
3. **Tokenización** del campo **overview**.

Generación de Embeddings

Para transformar los resúmenes en vectores numéricos, se utilizan técnicas de NLP:

- **Modelo utilizado**: **Sentence Transformers** con el modelo **all-MiniLM-L6-v2**.
- **Vectorización**: Cada resumen es transformado en un vector de características.
- **Almacenamiento**: Los vectores generados se almacenan junto con los datos originales en Cassandra para consulta rápida.

Sistema de Recomendación

El motor de recomendación opera bajo la técnica de **contenido basado en texto** usando **similitud coseno**.

Flujo de recomendación:

1. El usuario selecciona una serie.
2. Se obtiene el embedding del resumen de esa serie.
3. Se calcula la **distancia coseno** con todos los demás embeddings.
4. Se ordenan las series por mayor similitud.
5. Se devuelven las **N** recomendaciones más cercanas.

Base de Datos (Cassandra)

Se utiliza Apache Cassandra por su alta disponibilidad y escalabilidad horizontal.

```
keyspace_name = 'series'
query = (f"""CREATE TABLE IF NOT EXISTS {keyspace_name}.stream (
    show_id int,
    genre_name text,
    embeddings list<float>,
    embeddings_con_genero list<float>,
    vote_count int,
    name text,
    overview text,
    vote_average float,
    PRIMARY KEY ((genre_name), vote_count, show_id)
); """)

session.execute(query)
```

Captura de Actividad de Usuarios (Apache Kafka)

Los clics realizados por los usuarios en la interfaz web se envían a un **topic de Kafka**.

Estructura del evento:

json

```
{  
  "user_id": "abc123",  
  "series_id": "uuid-456",  
  "timestamp": "2025-06-08T12:34:56Z",  
  "action": "click"  
}
```

Proceso:

1. La web emite un evento al hacer clic en una serie.
2. El evento se publica en Kafka en un topic como `user_clicks`.
3. Un consumidor puede procesar los eventos para análisis, métricas o futuras recomendaciones basadas en comportamiento.

Interfaz Web

Desarrollada en html y python. Características:

- Buscador de series.
- Módulo de recomendaciones relacionadas.
- Historial o recomendaciones personalizadas (futuro).
- Registro de interacciones vía Kafka.

Futuras Mejoras

- Incorporar aprendizaje automático con historial de usuarios (recomendación híbrida).
- Implementar métricas de evaluación como precisión y recall.
- Reentrenar embeddings con datos propios o dominio específico.
- Añadir autenticación de usuarios.
- Dashboard de analíticas con los datos de Kafka.

Requisitos Técnicos

Backend

- Python 3.10+
- Sentence Transformers ([sentence-transformers](#))
- Cassandra Driver ([cassandra-driver](#))
- Kafka Producer ([confluent-kafka](#) o [kafka-python](#))

Base de Datos

- Apache Cassandra 4+

Streaming

- Apache Kafka